

# **PROPOSAL LIGA KOMATIK**

## **DATA MINING**



### **ANALISIS KINERJA MODEL *RNN*, *LSTM*, DAN *GRU* UNTUK PREDIKSI KEMARAU DENGAN INDEKS *SPEI* DI JAWA TIMUR DAN NUSA TENGGARA TIMUR**

Dosen Pembimbing:

Mardhani Riasetiawan, Dr.

Disusun Oleh:

Zulfikar Irham (21/475393/PA/20574)

Putri Awalia Shabrina (21/473042/PA/20364)

Shahnaz Izzati Frishila (21/472980/PA/20361)

**Universitas Gadjah Mada**

**Bulaksumur, Caturtunggal, Kec. Depok, Kabupaten Sleman, Daerah  
Istimewa Yogyakarta 55281**

**2023**

## 1. ABSTAK

Kekeringan adalah sebuah kondisi pada suatu wilayah ketika mengalami kondisi kering disertai dengan suhu udara yang tinggi. Kekeringan dapat menyebabkan kebakaran hutan, lahan pertanian gagal tanam, dan masyarakat kesulitan air. Indeks kekeringan yang digunakan adalah data Standard Precipitation Evapotranspiration Index (SPEI). SPEI merupakan salah satu indeks yang dapat digunakan untuk mengukur dan memantau tingkat kekeringan. SPEI yang digunakan pada penelitian ini adalah SPEI-6 dan SPEI-12 pada Provinsi Nusa Tenggara Timur (NTT) dan Jawa Timur. Model Deep Learning digunakan sebagai model untuk mengolah data index kekeringan. Model Deep Learning terus berkembang, mulai dari (Recurrent Neural Network) RNN, (Long Short-Term Memory) LSTM hingga (Gated Recurrent Unit) GRU. Ketiga model tersebut akan dibandingkan dan dievaluasi berdasarkan hasil Root Mean Squared Error (RMSE), Mean Absolute Percentage Error (MAPE), dan Mean Absolute Error (MAE). Hasil menunjukkan bahwa SPEI-6 memiliki nilai akurasi tertinggi jika menggunakan prediksi dengan model RNN. Sedangkan pada SPEI-12, terindikasi bahwa LSTM sebagai model prediksi terbaik.

Kata kunci : SPEI(*Standard Percipitation Evapotranspiration Index*), LSTM(*Recurrent Neural Network*), RNN(*Recurrent Neural Network*), GRU (*Gated Recurrent Unit*), *deep learning*

## 2. LATAR BELAKANG

Isu *Global Warming* kurang mendapat perhatian hingga saat ini. Masih sedikit masyarakat maupun lembaga yang tidak menganggap isu ini merupakan hal yang serius. Berdasarkan analisis dari 118 stasiun pengamatan BMKG, tercatat bahwa Indonesia memiliki suhu rata-rata yang lebih tinggi sejak Januari hingga Maret 2023 bila dibandingkan dengan suhu rata-rata per bulannya dari tahun 1991-2020.

Badan Meteorologi, Klimatologi dan Geofisika (BMKG) melakukan Analisis Dinamika Atmosfer Dasarian II Juni 2023. Pada analisis tersebut dinyatakan bahwa musim kemarau akan terjadi pada 56% wilayah di Indonesia. Wilayah tersebut termasuk pada wilayah Nusa Tenggara Timur (NTT) dan Jawa Timur. Kepala BMKG Stasiun Meteorologi El Tari, Agung Sudiono Abadi mengatakan bahwa provinsi Nusa Tenggara Timur (NTT) memiliki tingkat curah hujan yang rendah karena terdapat '*trough pressure*' (daerah tekanan rendah) pada wilayah pesisir

utara Australia. Selain itu, dengan suhu rata-rata sepanjang tahun 1991-2020 yang kian meningkat, mengancam wilayah NTT mengalami risiko bencana kekeringan meteorologis, kebakaran hutan, dan kekurangan air bersih. Salah satu risiko kekeringan seperti banyak lahan pertanian yang gagal tanam dan masyarakat yang kesulitan air bersih pernah dialami di Sumba Timur, NTT.

Menurut BMKG wilayah Jawa Timur, prakiraan curah hujan di Jawa Timur dibawah normal serta jadwal datangnya musim kemarau yang maju. Selain itu, menurut hasil pemetaan Badan Penanggulangan Bencana Daerah (BPBD), kekeringan di Jawa timur pada tahun 2023 berisiko terjadi di 27 Kabupaten/Kota dengan estimasi penduduk yang terdampak lebih dari 1,5 juta jiwa. Kemudian, BRIN menyatakan bahwa fenomena El Nino yang meningkatkan ancaman kekeringan yang tinggi berpotensi menurunkan produksi padi hingga 1 Juta Ton.

BMKG telah menggunakan metode WRF (Weather Research and Forecasting) yang merupakan model cuaca dan iklim numerik. Model tersebut digunakan untuk memprediksi kondisi atmosfer dan cuaca pada wilayah tertentu. WRF dikembangkan oleh National Center for Atmospheric Research (NCAR), bersama dengan berbagai mitra penelitian di seluruh dunia. Model WRF dirancang untuk memberikan peramalan cuaca jangka pendek (hingga beberapa hari) dan jangka menengah (hingga beberapa minggu) dengan resolusi spasial dan temporal yang tinggi (Sulistiyono, Zuliandry, dan Haryanto, 2023).

Data yang disajikan oleh BMKG adalah data yang cukup akurat tetapi hanya bersifat temporal dan hanya menyajikan data dengan jangka waktu menengah (hingga beberapa minggu). Meskipun begitu, seiring dengan adanya perkembangan kecerdasan buatan, pemodelan Deep Learning juga semakin berkembang sehingga model yang sudah ada terus disempurnakan untuk mencapai hasil yang optimal. Salah satu model yang kian berkembang adalah model Recurrent Neural Network (RNN). RNN kemudian berkembang hingga menghasilkan LSTM (Long-Short Term Memory) dan GRU (Gated Recurrent Unit).

Berdasarkan penjabaran di atas, penulis membandingkan model RNN, LSTM, dan GRU untuk mengetahui model terbaik yang dapat memprediksi kekeringan pada suatu wilayah di Indonesia.

Data wilayah yang digunakan yaitu NTT dan Jawa Timur. NTT memiliki curah hujan yang rendah setiap tahunnya sehingga memerlukan aksi mitigasi secara komprehensif dan sejak dini untuk mengantisipasi dampak musim kemarau. Sedangkan, data Jawa Timur juga diprioritaskan karena merupakan daerah lumbung padi nasional sejak tahun 2020. Iklim dan ekosistem yang dimiliki oleh Jawa Timur harus dijaga sebaik mungkin sehingga pasokan sumber pangan terbesar Indonesia juga dapat terjaga. Oleh karena itu, NTT dan Jawa Timur digunakan sebagai indeks kekeringan yang akan diolah menggunakan RNN, LSTM, dan GRU dengan tujuan dapat menemukan model yang optimal dari perbandingan ketiga model tersebut.

### 3. TUJUAN

Tujuan dari penelitian ini adalah untuk membandingkan ketiga performa dari model *Recurrent Neural Network* (RNN), *Long Short Term Memory* (LSTM), dan *Gated Recurrent Unit* (GRU) untuk memprediksi kemarau dari data *Standardised Precipitation-Evapotranspiration Index* (SPEI) yang terdiri dari SPEI-6 dan SPEI-12 yang berbentuk *time series* untuk provinsi Jawa Timur dan Nusa Tenggara Timur (NTT).

### 4. MANFAAT

Manfaat yang dapat diberikan dari pengembangan ini di antaranya:

1. Kontribusi dalam pengembangan model *Deep Learning LSTM* (*Long Short-Term Memory*), *RNN* (*Recurrent Neural Network*) dan GRU (*Gated Recurrent Unit*) berdasarkan data *SPEI* (*Standardized Precipitation Evapotranspiration Index*) untuk prediksi kemarau yang lebih efektif.
2. Meningkatkan rencana pengelolaan air yang adaptif oleh masyarakat dan pemangku kepentingan lainnya untuk menghadapi ancaman kekeringan di Provinsi Nusa Tenggara Timur.
3. Meningkatkan rencana pengelolaan air yang adaptif oleh petani dan pemangku kepentingan lainnya untuk hasil pertanian yang lebih baik di Provinsi Jawa Timur.

## 5. BATASAN

Batasan masalah dalam penelitian ini adalah

1. Penelitian ini hanya menghasilkan model yang dapat memprediksi nilai rata-rata dari SPEI-6 dan SPEI-12 pada provinsi Jawa Timur dan Nusa Tenggara Timur (NTT).
2. Penelitian ini tidak memvisualisasikan peta wilayah Jawa Timur dan NTT dalam visualisasi menggunakan data SPEI-6 dan SPEI-12.

## 6. KAJIAN TERKAIT YANG RELEVAN

Pertama, kajian terkait yang relevan dengan penelitian ini memiliki judul *A New Deep Learning Method for Meteorological Drought Estimation Based On Standard Precipitation Evapotranspiration Index*. Jurnal tersebut meneliti kekeringan dengan mempertimbangkan dampak kekeringan yang dapat menurunkan sosial ekonomi, mengurangi produktivitas, dan merusak ekosistem. Data yang digunakan pada penelitian dalam jurnal tersebut adalah index kekeringan yang berdasarkan Standard Precipitation Evapotranspiration Index (SPEI) pada berbagai lokasi di Türkiye. Pada kasus ini, SPEI digunakan karena penelitian ini bertumpu pada temperatur dan nilai presipitasi data. Setelah data telah didapat, data tersebut diimplementasikan pada model LSTM, CNN, ANN, dan lain sebagainya. Peneliti akan membandingkan performa hasil CNN-LSTM sebagai rancangan model terbaru yang telah dibuat oleh peneliti, dengan Root Mean Squared Error (RMSE), Mean Absolute Error (MAE), Mean Deviation Error (MADE), dan koefisien determinan ( $R^2$ ). Penelitian tersebut juga memberikan hasil performa eksperimen *forecasting* dengan parameter SPEI 3, 6, 9, dan 12 bulan. Kasus pada jurnal ini fokus pada estimasi dan *monitoring* parameter kekeringan yang berlokasi di Tigris-Euphrates, Türkiye. (Yalçın, Eşit, dan Çoban, 2023)

Kedua, kajian terkait yang relevan adalah jurnal dengan judul “*Application of a hybrid ARIMA-LSTM model based on the SPEI for drought forecasting*”. Kajian ilmiah tersebut mengusulkan model hybrid berdasarkan metode deep learning yang mengintegrasikan model Autoregressive Integrated Moving Average (ARIMA) dan Long Short Term Memory (LSTM) untuk meningkatkan akurasi pada prediksi kekeringan dengan jangka waktu pendek. Penelitian ini mengindikasikan bahwa model hybrid memiliki akurasi yang tinggi untuk SPEI dalam jangka waktu yang lama dan sebaliknya memiliki akurasi yang rendah untuk SPEI dalam jangka

waktu yang pendek. Hasil pada kajian ini menunjukkan bahwa model hybrid memiliki tingkat akurasi yang lebih tinggi daripada single model. (Xu, dkk., 2022)

Kajian ketiga yang memiliki relevansi dengan penelitian ini adalah jurnal dengan judul *“Application of Informer Model Based on SPEI for Drought Forecasting”*. Jurnal tersebut memiliki tujuan untuk melakukan metode forecasting tingkat kekeringan dengan model Informer. Jurnal tersebut memberikan perbandingan akurasi model ARIMA, LSTM, dan Informer pada skala waktu SPEI yang berbeda. Jurnal tersebut menegaskan bahwa indeks kekeringan merupakan faktor yang krusial dalam penilaian kuantitatif tingkat kekeringan. SPEI terbuat dari algoritma yang digunakan SPI dan PDSI dan menggabungkan fitur multi-skala untuk mengevaluasi efek suhu variasi kondisi kekeringan. Jurnal ini menggunakan data penelitian ini memilih rentang waktu SPEI pada 1 bulan (SPEI 1), 3 bulan (SPEI 3), 6 bulan (SPEI 6), 9 bulan (SPEI 9), 12 bulan (SPEI 12), dan 24 bulan (SPEI 24). Dengan menggunakan multi-skala dari data SPEI sejak 1960-2007 sebagai data latih dan data prediksi yang digunakan adalah sejak 2008-2020. Hasilnya mengindikasikan bahwa semakin besar skala waktu yang digunakan, maka performa dari setiap model meningkat. Perbandingan yang dihasilkan model Informer memiliki tingkat akurasi yang paling tinggi dibandingkan dengan ARIMA dan LSTM dengan nilai SPEI yang paling baik ada pada rentang waktu 24 Bulan (SPEI 24). (Shang, dkk., 2023)

## **7. SOLUSI USULAN**

### **A. Deskripsi solusi**

Model ML sekarang menjadi canggih dan terus berkembang sehingga banyak model yang dapat dilakukan untuk mengolah data. Hal tersebut menunjukkan bahwa banyak kemungkinan yang dapat digunakan untuk mendapatkan hasil olahan data yang diinginkan. Menyadari terdapat banyak model ML yang ada, maka kami mencari metode yang dapat memberikan hasil terbaik. Penelitian ini bertujuan untuk mengeksplorasi metode terbaik yang ada dalam kemampuannya untuk menganalisis indeks kekeringan. Model yang digunakan pada penelitian ini adalah LSTM, RNN, dan GRU.

Saat memproses data SPEI atau Standardized Precipitation Evaporation Index untuk perkiraan kekeringan di wilayah Provinsi Jawa Timur dan Provinsi Nusa Tenggara Timur,

kami menerapkan beberapa metode *deep learning* seperti LSTM, RNN dan GRU. Metode ini dirancang khusus untuk menangani data deret waktu yang kompleks dan mampu menangani ketergantungan jangka panjang.

Percobaan pertama dengan menerapkan metode LSTM yang memanfaatkan jaringan saraf berulang dalam mekanisme sel memori. LSTM lalu menggunakan data yang sudah dipilih yaitu data SPEI 6 dan SPEI 12 untuk dilatih pemodelan dan dipelajari hubungan temporal antar variabelnya yang relevan. Dengan memanfaatkan sel memori, LSTM mampu mengingat informasi masa lalu dalam proses prediksi kekeringan masa depan.

Percobaan kedua menggunakan metode RNN yang pendekatannya mirip LSTM, namun ada perbedaan dalam penggunaan sel memori yang lebih sederhana dibandingkan LSTM. RNN juga memodelkan hubungan temporal dalam data SPEI naming dalam dependensi jangka Panjang yang terbatas.

Terakhir digunakan metode GRU yang memiliki jaringan saraf berulang seperti LSTM. GRU mengatur aliran informasi dalam sel memori menggunakan mekanisme gerbang yang lebih sederhana. Gru juga dapat mempertahankan informasi lebih lama dari RNN, namun tidak seefektif penggunaan LSTM

Setelah menjalankan ketiga metode dan juga berdasarkan hasil evaluasi kinerja dengan beberapa metrik seperti root mean square error (RMSE), mean absolute error (MAE), dan mean absolute percentage error (MAPE), dapat disimpulkan bahwa pengolahan data SPEI 6 dan 12 di Provinsi Jawa Timur dan Provinsi Nusa Tenggara Timur dari tahun 1951 hingga 2023 secara keseluruhan lebih efektif menggunakan beberapa metode tertentu dibanding metode lainnya.

## **B. Dataset dan Indeks Kekeringan Standardized Precipitation-Evapotranspiration Index (SPEI)**

Dataset yang digunakan pada penelitian ini adalah data *Standardised Precipitation-Evapotranspiration Index* (SPEI) dengan berbagai macam skala, yaitu SPEI-6 dan SPEI-12.

Dataset ini diperoleh dari SPEI Global Drought Monitor yang dibuat oleh Spanish National Research Council (CSIC) (<https://spei.csic.es/map/maps.html#months=1#month=4#year=2023> diakses pada 17 Juni 2023). Bentuk dataset yang digunakan adalah *time series* dalam kurun waktu 72 tahun dari Januari tahun 1951 hingga Mei 2023. Area pada data yang diambil adalah Provinsi Jawa Timur dan Nusa Tenggara Timur (NTT).

Kekeringan adalah masalah serius yang sering muncul ketika musim kemarau tiba dan menyebabkan banyak tempat di Indonesia mengalami masalah kekurangan air atau defisit air atau kekeringan. Dari perspektif kebencanaan kekeringan merupakan keadaan ketika suatu wilayah kekurangan curah hujan dalam periode waktu tertentu (umumnya dalam satu musim atau lebih) yang menyebabkan kekurangan air untuk berbagai kebutuhan (Indarto dkk, 2014).

Fenomena kekeringan dapat dipantau dengan menggunakan indeks kekeringan. *Standardized Precipitation-Evapotranspiration Index* (SPEI) merupakan salah satu indeks kekeringan yang paling umum digunakan untuk tujuan peramalan setelah diperkenalkan oleh Vincente Serrano dkk., 2010. Hal ini terutama karena ketergantungannya pada data curah hujan dan suhu, kecuali seperti *Standardized Precipitation Index* (SPI) yang hanya menggunakan data curah hujan. Perhitungan SPEI meliputi penentuan “neraca air iklim” yang melibatkan penggunaan curah hujan dan potensi evapotranspirasi. Perhitungan SPEI dapat dilakukan pada berbagai skala waktu, mulai dari 1 bulan hingga 24 bulan, yang menggambarkan tipe kekeringan yang berbeda (Vincente Serrano dkk., 2010). Untuk menghitung indeks SPEI pada skala waktu yang berbeda ( $n = 1,3$ ) neraca air iklim bulanan digabungkan dengan jumlah pergerakan  $n$ -bulan, yaitu nilai bulanan saat ini dan nilai bulanan  $n-1$  sebelumnya. Misalnya data akumulasi bulanan untuk Januari-Februari-Maret menentukan indeks untuk bulan Maret (Vicente Serrano dkk., 2010). Neraca air iklim dihitung pada skala waktu yang berbeda, dan nilai yang dihasilkan disesuaikan dengan distribusi probabilitas log-logistik untuk mengubah nilai asli menjadi satuan standar (Beguería dkk., 2014). Umumnya, skala waktu yang lebih pendek (1–3 bulan) mewakili kekeringan meteorologi, sedangkan skala waktu 3–6 bulan menggambarkan kekeringan pertanian, sedangkan skala waktu yang lebih besar, 12–24 bulan cocok untuk menggambarkan kekeringan hidrologi (Mishra dan Singh, 2010). Tabel 1 menunjukkan berbagai klasifikasi kekeringan sesuai indeks SPEI.



Tabel 1. Klasifikasi kekeringan sesuai nilai SPEI (Rhee and Im, 2017).

Klasifikasi SPEI	Kategori
$\leq -2.0$	Kering Ekstrem
-1.99~-1.5	Sangat Kering
-1.49~-1.0	Cukup Kering
-0.99-0.99	Normal
1.0-1.49	Cukup Basah
1.5-1.99	Sangat Basah
$\geq 2.0$	Basah Ekstrem

### C. Metode Penelitian

Metode yang akan digunakan pada penelitian kali ini adalah,

1. Pengambilan data SPEI-6 dan SPEI-12 pada Provinsi Jawa Timur dan NTT.
2. Input data SPEI-6 dan SPEI-12 pada Provinsi Jawa Timur dan NTT.
3. Melakukan *pre-processing* data pada masing-masing SPEI, yang terdiri dari normalisasi data dan membuat data *time series* menjadi *input/feature* dan *output/label* dengan menggunakan metode *sliding window*.
4. Data *splitting* menjadi data *train*, *validation*, dan *test*.
5. Melakukan pemodelan data dengan model *Recurent Neural Network* (RNN), *Long Short Term Memory* (LSTM), dan *Gated Recurent Unit* (GRU) pada masing-masing SPEI.
6. Melakukan denormalisasi data.

7. Mengevaluasi model dari nilai metrik yang diperoleh, yaitu Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan Mean Absolute Percentage Error (MAPE) pada masing-masing SPEI.
8. Membandingkan nilai metrik yang diperoleh untuk mencari model yang terbaik pada masing-masing SPEI.

#### a. Preprocessing Data

Pre-processing data merupakan tahapan dalam data mining untuk memproses data dengan menghilangkan data yang berada di luar rentang data lainnya yang disebut *outlier* atau membuat data menjadi lebih mudah dipahami (Sari dkk., 2023). Pre-processing data dilakukan dengan mengecek apakah ada data yang *null* atau kosong, lalu datanya dapat dihapus dan normalisasi. Normalisasi data dilakukan dengan penskalaan rentang nilai data yang tepat karena varians yang signifikan tidak memungkinkan digunakan secara langsung (Patel dkk., 2020).

Pada penelitian ini dilakukan tahap pre-processing data, yaitu melakukan normalisasi data dengan min-max normalisasi yang diformulasikan pada persamaan (1) yang berfungsi untuk membuat nilai rentang data menjadi 0-1.

$$x_{normalized} = \frac{x_{original} - x_{min}}{x_{max} - x_{min}} \quad (1)$$


$X_{original}$  adalah yang akan dinormalisasi, dan  $X_{normalized}$  adalah data yang sudah dinormalisasi.  $X_{min}$  adalah nilai minimum dari semua data dan  $X_{max}$  adalah nilai maksimum dari semua data. Min-max Normalisasi dilakukan untuk meminimalkan kesalahan dalam pemodelan data (Rizkilloh dan Widiyanesti, 2022).

Selanjutnya, dengan membuat *sliding window* (SW) pada data *time series* yang membuat data berubah menjadi *input/feature* dan *output/label* agar model RNN, LSTM, dan GRU dapat melakukan hasil prediksi yang baik. Metode diimplementasikan untuk membangun *input/feature* dan *output/label* untuk sampel data latih berdasarkan data *time series*. Contoh sampel data latih pada *time series* yang diperoleh dengan metode SW dapat dinyatakan sebagai berikut:

$$\{S_{t-\square h}, S_{t-\square h+1}, \dots, S_{t-3}, S_{t-2}, S_{t-1}\} \rightarrow \{S_t\} \quad (2)$$

Dengan  $S = \{S_1, S_2, S_3, \dots, S_N\}$  merupakan sebuah barisan,  $\{S_{t-\square h}, S_{t-\square h+1}, \dots, S_{t-3}, S_{t-2}, S_{t-1}\}$  merupakan *input/feature* pada waktu  $t$ ,  $\{S_t\}$  merupakan *output/label* pada waktu  $t$ , dan  $\square h$  menunjukkan *window size*. Metode SW ini bekerja dengan

cara menahan sisi bagian kiri  $S_1$  dan bergerak atau memindai melalui interval waktu  $N - \Delta h$  untuk mencapai titik sisi kanan  $S_{N-\Delta h}$  dari data *time series*. Selama proses ini, setiap pemindaian menyediakan sampel data untuk dilatih (Chen dkk., 2021).



Gambar 1. Ilustrasi Metode *sliding window* (SW) (Chen dkk., 2021)

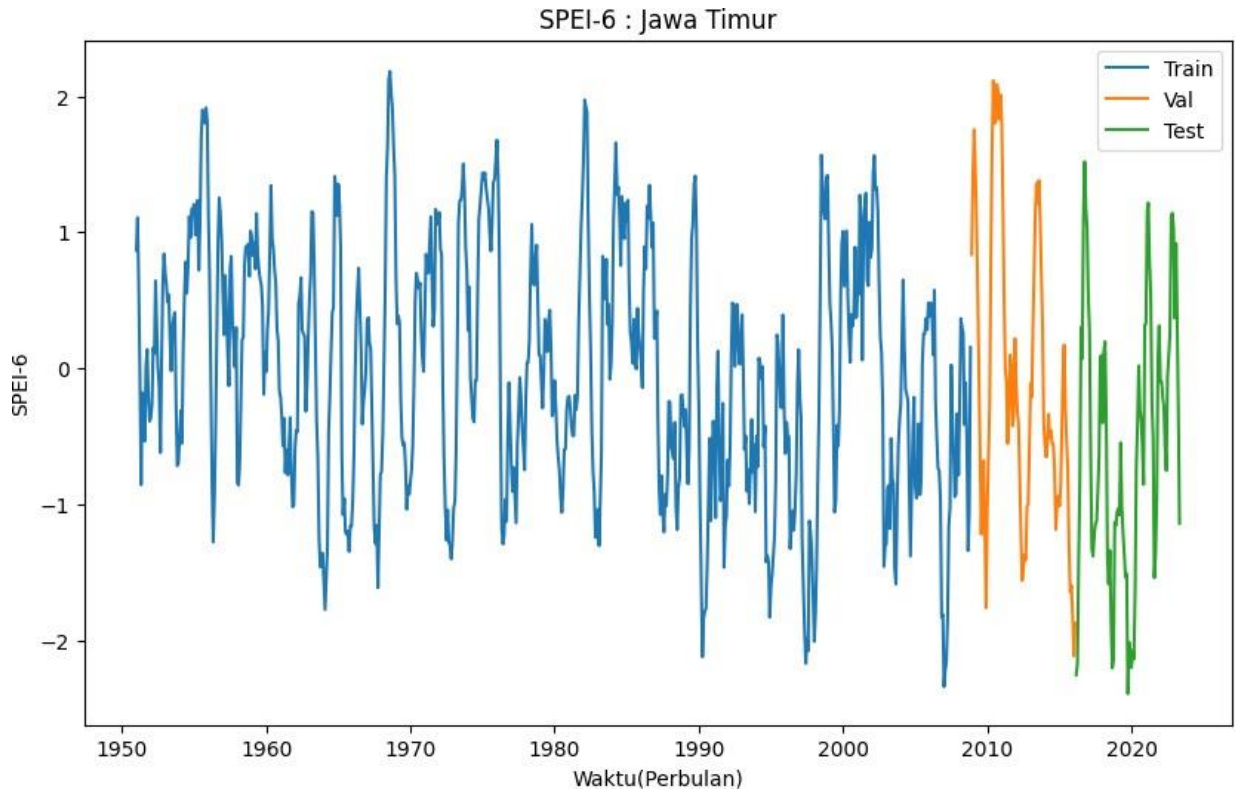
Penelitian ini menggunakan window size dengan ukuran 12 sehingga dari 12 data SPEI perbulan dapat memprediksi nilai SPEI pada satu bulan berikutnya. Contoh sampel SPEI-6 Provinsi Jawa Timur yang menggunakan metode SW terdapat pada gambar 2.

	Target-12	Target-11	Target-10	Target-9	Target-8	Target-7	Target-6	Target-5	Target-4	Target-3	Target-2	Target-1	Target
DATE													
1952-01-01	0.86721	1.10779	0.63219	-0.03850	-0.85571	-0.17925	-0.29551	-0.53423	0.00858	0.13887	-0.20378	-0.38856	-0.36436
1952-02-01	1.10779	0.63219	-0.03850	-0.85571	-0.17925	-0.29551	-0.53423	0.00858	0.13887	-0.20378	-0.38856	-0.36436	-0.26737
1952-03-01	0.63219	-0.03850	-0.85571	-0.17925	-0.29551	-0.53423	0.00858	0.13887	-0.20378	-0.38856	-0.36436	-0.26737	0.15000
1952-04-01	-0.03850	-0.85571	-0.17925	-0.29551	-0.53423	0.00858	0.13887	-0.20378	-0.38856	-0.36436	-0.26737	0.15000	0.10844
1952-05-01	-0.85571	-0.17925	-0.29551	-0.53423	0.00858	0.13887	-0.20378	-0.38856	-0.36436	-0.26737	0.15000	0.10844	0.64417

Gambar 2. Sampel Data SPEI-6 Provinsi Jawa Timur Setelah Menggunakan Metode SW

## b. Data Splitting

Pada tahap ini, dilakukan pemisahan data menjadi tiga bagian, yaitu data *train*, *validation*, dan *test* dengan proporsi masing-masing 80%, 10%, dan 10%. Data splitting ini digunakan untuk ketiga model yang digunakan, yaitu RNN, LSTM, dan GRU. Gambar 2 merupakan sampel grafik SPEI-6 Provinsi Jawa Timur yang telah dilakukan data *splitting*.



Gambar 2. Sampel Hasil *Splitting* SPEI-6 Provinsi Jawa Timur

### c. Modelling

Pada tahap *modelling* penelitian ini menggunakan tiga model, yaitu RNN, LSTM, dan GRU. Framework yang digunakan dalam penelitian ini adalah Tensorflow. Kemudian, platform yang digunakan adalah Google Collaboratory dengan fasilitas GPU gratis yang dapat mempercepat proses *running*. Parameter yang digunakan untuk penelitian dari ketiga model tersebut terdapat pada Tabel 2 sebagai berikut.

Tabel 2. Parameter *modelling* RNN, LSTM, dan GRU


Parameter	RNN	LSTM	GRU
Neuron Layer 1	200	200	200
Neuron Layer 2	200	200	200
Activation Function	tanh	tanh	tanh
Dropout	0.2	0.2	0.2

Dense	1	1	1
Learning Rate	0.0001	0.0001	0.0001
Loss Function	Mean Squared Error (MSE)	Mean Squared Error (MSE)	Mean Squared Error (MSE)
Optimizer	Adam	Adam	Adam
Epoch	300	300	300
Step per Epoch	50	50	50

Dapat dilihat pada Tabel 2. Parameter yang digunakan pada ketiga model tersebut adalah sama sehingga dapat lebih mudah dalam mengevaluasi model yang terbaik dari ketiga metrik yang dibandingkan pada penelitian ini, yaitu Root Mean Squared Error (RMSE), Mean Absolute Percentage Error (MAPE), dan Mean Absolute Error (MAE). Berikut merupakan penjelasan dari ketiga model yang digunakan pada penelitian ini.

- Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN) adalah salah satu arsitektur jaringan saraf yang diproses secara berulang untuk memproses input yang biasanya berupa data berurutan seperti deret waktu. Perbedaan dari RNN dengan jaringan saraf tradisional adalah dalam RNN setiap pemrosesan yang dihasilkan tidak hanya dipengaruhi oleh masukan arus tetapi dipengaruhi oleh suatu keadaan internal yang merupakan hasil dari pemrosesan input sebelumnya. Arsitektur dari RNN dirancang pada waktu  $t - 1$  mempengaruhi keputusan pada waktu  $t$ . Dengan demikian, keputusan terkait dengan jaringan akan merespons untuk data baru tergantung pada dua hal, (1) input saat ini dan (2) output dari masa lalu. (Masri, Saepudin, dan Adytia, 2020.)



Gambar 3. Ilustrasi *Recurrent Neural Network* (RNN) (Shinde, dkk., 2021.)

RNN bekerja dengan menghitung outputnya secara iteratif dua persamaan berikut.

$$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h), \quad (3)$$

$$y_t = W_{hy}h_t + b_y, \quad (4)$$


Dengan  $x$  sebagai input,  $y$  sebagai urutan output,  $h$  adalah urutan vektor tersembunyi pada irisan waktu  $t = 1$  hingga  $T$ . Kemudian,  $W$  mewakili matriks bobot dan  $b$  mewakili bias.  $\tanh$  adalah fungsi aktivasi yang digunakan pada lapisan tersembunyi.  $\tanh$  memiliki range -1 hingga 1 dengan nilai output  $y_t$ .  $\tanh$  memiliki rumus sebagai berikut.

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (5)$$

(Masri, Saepudin, dan Adytia, 2020)

- Long Short-Term Memory (LSTM)

*Long Short-Term Memory* (LSTM) merupakan arsitektur jaringan saraf berulang atau disebut *Recurrent Neural Network* (RNN) untuk menangani data yang berurutan, LSTM dikembangkan untuk meningkatkan RNN tradisional, dan secara efektif menangani masalah ketergantungan yang berkepanjangan dengan menggunakan tiga mekanisme gerbang (*gate*) dan unit memori. Berbeda dengan RNN biasa, LSTM menggabungkan sel memori untuk menentukan apakah informasi itu tersedia. Kunci pada LSTM itu terdapat pada keadaan selnya. Untuk melindungi dan mengontrol keadaan sel memori, tiga gerbang kontrol ditempatkan pada sel memori yang terdiri dari *input gate*, *forget gate*, dan *output gate*. Setiap gerbang kontrol terdiri dari lapisan jaringan syaraf yang mengandung fungsi *sigmoid*, *tanh*, dan perkalian skalar (*dot product*) (Shang dkk., 2023).. Struktur sel memori LSTM diilustrasikan pada gambar 4.



Gambar 4. Struktur Sel Memori pada LSTM (Xu dkk., 2022)

Hidden layer pada LSTM disebut juga dengan sel memori, perhitungannya dapat dinyatakan dalam persamaan sebagai berikut:

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (6)$$

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (7)$$

$$C_t = f_t \otimes C_{t-1} + i_t \otimes \tilde{C}_t \quad (8)$$

$$\tilde{C}_t = \tanh(W_{\tilde{C}} x_t + U_{\tilde{C}} h_{t-1} + b_{\tilde{C}}) \quad (9)$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (10)$$

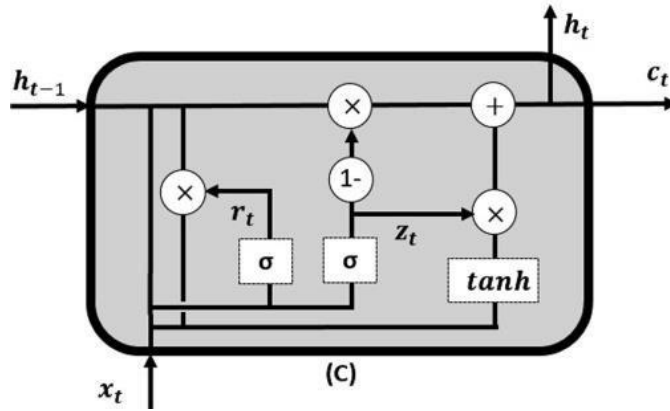
$$h_t = o_t \otimes \tanh(C_t) \quad (11)$$

Dengan  $i$ ,  $f$ ,  $C$ , dan  $o$  menunjukkan *input gate*, *forget gate*, vektor keadaan sel, dan *output gate*.  $W$  menunjukkan matriks dari *weights*,  $b$  menunjukkan bias vektor, dan  $U$  menunjukkan matriks *weights* ke yang *hidden*.  $\sigma$  dan  $\tanh$  adalah fungsi aktivasi sigmoid dan tangen hiperbola fungsi aktivasi. Perkalian elementwise dari kedua vektor dilambangkan dengan  $\otimes$  (Xu dkk., 2022).

- Gated Recurrent Unit (GRU)

Gated Recurrent Unit (GRU) dibuat ketika model RNN perlu dikembangkan untuk mengatasi masalah *long memory dependency* ketika menghadapi skala waktu yang panjang karena RNN akan mengalami Vanishing Gradient ketika melakukan BTT. GRU merupakan pengembangan dari model Long Short Term Memory (LSTM) yang memiliki kelebihan bobot dan parameter yang dilatih lebih sedikit dari LSTM sehingga kecepatan pelatihan model lebih cepat dari pada LSTM. Selain itu, implementasinya lebih sederhana dari LSTM. GRU memiliki bobot latih dan parameter yang lebih sedikit

daripada LSTM karena Gate GRU lebih sedikit dibandingkan dengan LSTM. LSTM memiliki tiga gerbang yaitu *forget gate* ( $f_t$ ), *input gate* ( $i_t$ ), dan *output gate* ( $O_t$ ). Gerbang *forget* dan *input* digabungkan menjadi *update gate* ( $z$ ). GRU memiliki gerbang kedua yaitu *reset gate* ( $r$ ). (Caniago, Kaswidjanti, dan Juwairiah, 2021)



Gambar 5. Ilustrasi *Gate Recurent Unit* (GRU)

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

Keterangan:

$z_t$  = *update gate*

$r_t$  = *reset gate*

$z_t$  = *candidates value*

$h_t$  = *output atau hidden state*

$h_{t-1}$  = *output dari state*

$W_z$  = bobot *update* yang terkoneksi dengan *input*

$W_r$  = bobot *reset* yang terkoneksi dengan *input*

$W_h$  = bobot *candidates* yang terkoneksi dengan *input*

$U_z$  = bobot *update* yang terkoneksi dengan output sebelumnya

$\sigma$  = *sigmoid*

$\tanh$  = fungsi aktivasi *tanh*

$x_t$  = *input*

$h_{t-1}$  = *output sebelumnya*



$b_z$  = bias *update*

$U_r$  = bobot reset yang terkoneksi dengan output sebelumnya

$U_h$  = bobot candidates yang terkoneksi dengan output sebelumnya

$b_r$  = bias reset

$b_h$  = bias candidates

#### **d. Denormalisasi**

Setelah mendapatkan hasil prediksi dari proses *modelling*, maka sebelum menghitung akurasi hasil prediksi harus dilakukan denormalisasi yaitu data diubah menjadi nilai real kembali. Karena data hasil prediksi masih berupa data berbentuk range interval yang dilakukan pada normalisasi data. Tujuan denormalisasi adalah agar output mudah dibaca dan mudah dimengerti. Dibawah ini adalah rumus untuk denormalisasi.

$$d = d' (max - min) + min \quad (8)$$

Dengan,

$d$  = Nilai hasil denormalisasi

$d'$  = Nilai data normalisasi

$max$  = Nilai maksimum dari data aktual

$min$  = Nilai minimum dari data aktual

(Wiranda dan Sadikin, 2019).

#### **D. Perbedaan dengan solusi sebelumnya dari kajian terkait**

Penelitian ini memiliki perbedaan solusi dengan kajian terkait yang relevan. Perbedaan tersebut ada pada pemilihan metode untuk mengoptimalkan solusi yang telah didapatkan. Solusi yang diberikan oleh kajian terkait pertama berfokus pada estimasi dan *monitoring* kekeringan sehingga bereksperimen dengan membandingkan beberapa model seperti LSTM, CNN, dan ANN. Solusi kajian terkait kedua menawarkan model hybrid dari Autoregressive Integrated Moving Average (ARIMA) dan Long Short Term Memory (LSTM), yaitu model ARIMA-LSTM. Terakhir, pada solusi kajian terkait ketiga memberikan solusi dengan menggunakan Informer. Dengan begitu, terlihat bahwa pada semua kajian terkait yang telah dibahas, solusi yang ditawarkan di antaranya dengan model hybrid seperti model CNN-LSTM, ARIMA-LSTM, dan model Informer. Sedangkan solusi yang ditawarkan pada penelitian kali

ini adalah dengan melakukan perbandingan pada RNN (Recurrent Neural Network), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU).

#### **E. Metrik evaluasi yang digunakan**

Pada penelitian ini digunakan tiga indikator metrik evaluasi, yaitu Root Mean Squared Error (RMSE), Mean Absolute Percentage Error (MAPE), dan Mean Absolute Error (MAE) diperkenalkan untuk mengevaluasi kinerja dari algoritma deterministik. Dapat dinyatakan pada persamaan (12)-(14). Nilai RMSE, MAPE, dan MAE yang kecil menunjukkan bahwa performa model yang baik.

$$\text{RMSE} = \sqrt{\frac{\sum_{t=1}^N (\hat{Y}_t - Y_t)^2}{N}} \quad (12)$$

$$\text{MAPE} = \frac{1}{N} \sum_{t=1}^N \frac{|\hat{Y}_t - Y_t|}{\hat{Y}_t} \quad (13)$$

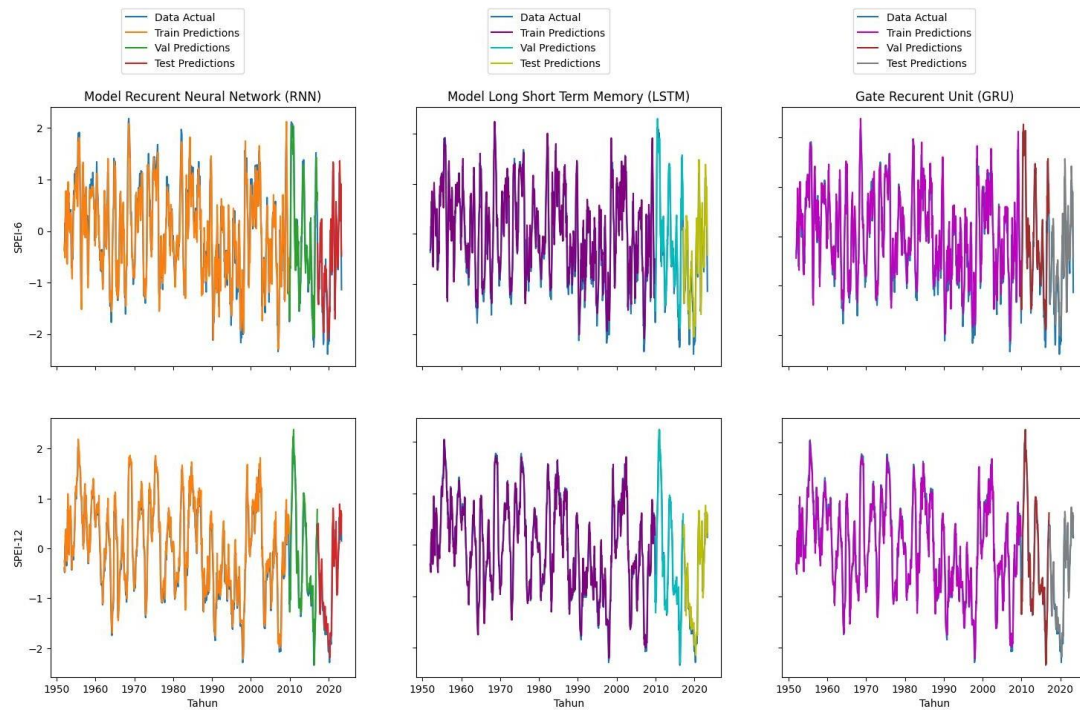
$$\text{MAE} = \frac{1}{N} \sum_{t=1}^N |\hat{Y}_t - Y_t| \quad (14)$$

Dengan  $\hat{Y}_t$  dan  $Y_t$  secara berurutan adalah nilai hasil prediksi dan nilai data sesungguhnya.  $N$  merupakan jumlah sampel seluruh data (Chen dkk., 2021).

### **8. HASIL EKSPERIMEN DAN PENGUJIAN**

Hasil eksperimen dan pengujian pada penelitian ini disajikan dengan analisis ekstensif yang dilakukan pada dua provinsi yang berbeda.

#### **A. Provinsi Jawa Timur**



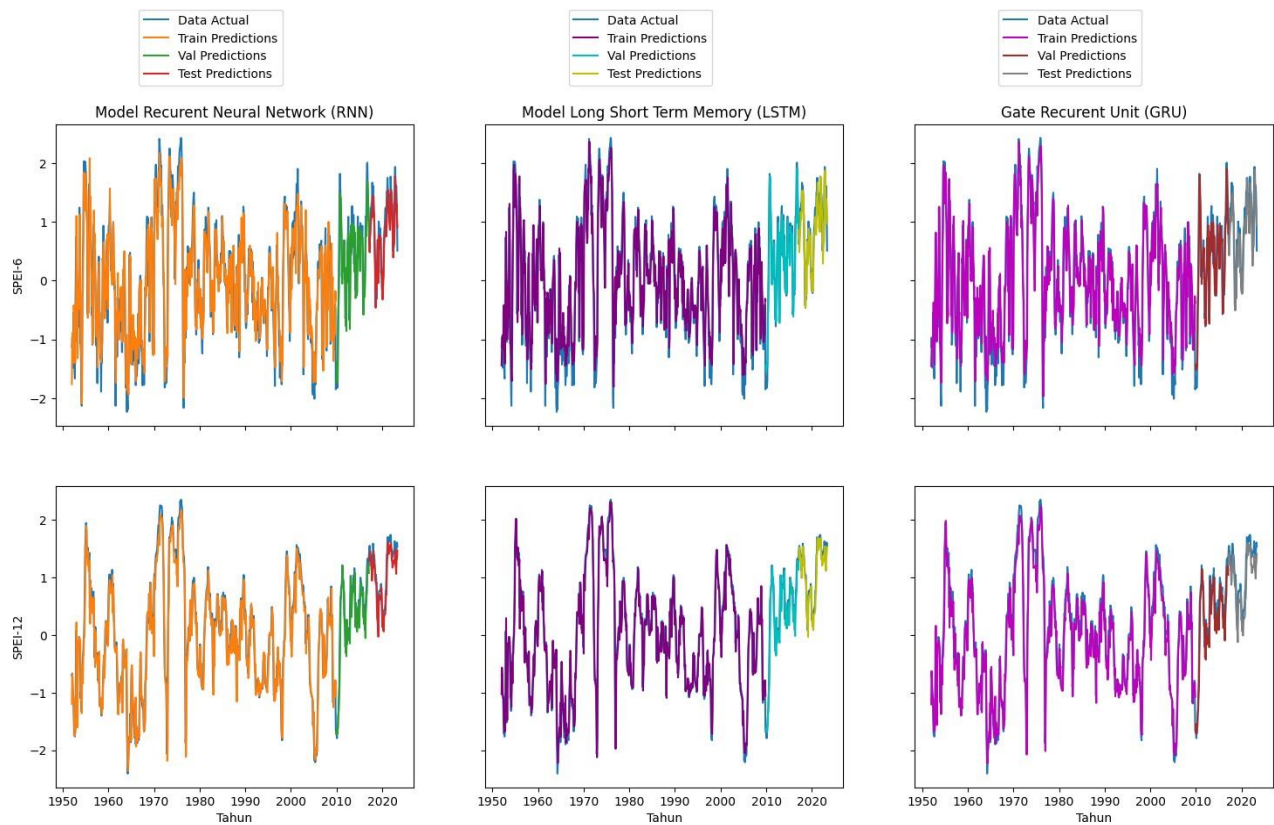
Gambar 6. Hasil Prediksi SPEI-6 dan SPEI-12 Provinsi Jawa Timur

Tabel 3. Evaluasi Metrik Hasil Prediksi SPEI Provinsi Jawa Timur

Metode	Metrik	Tipe SPEI					
		SPEI-6			SPEI-12		
		Training	Validasi	Testing	Training	Validasi	Testing
LSTM	RMSE	0.37	0.35	0.47	0.23	0.23	0.27
	MAPE	1.67	1.38	1.12	1.13	0.46	1.24
	MAE	0.28	0.29	0.38	0.17	0.17	0.22
RNN	RMSE	0.32	0.33	0.39	0.24	0.25	0.29
	MAPE	1.4	1.18	1	1.1	0.61	1.72

	MAE	0.25	0.26	0.32	0.19	0.19	0.25
GRU	RMSE	0.35	0.36	0.45	0.23	0.24	0.27
	MAPE	1.77	1.47	1.03	1.12	0.47	1.29
	MAE	0.27	0.29	0.37	0.17	0.18	0.22

## B. Provinsi Nusa Tenggara Timur



Gambar 7. Hasil Prediksi SPEI-6 dan SPEI-12 Provinsi Jawa Timur

Tabel 4. Evaluasi Metrik Hasil Prediksi SPEI Provinsi Jawa Timur

Metode	Metrik	Tipe SPEI					
		SPEI-6			SPEI-12		
		Training	Validasi	Testing	Training	Validasi	Testing
LSTM	RMSE	0.47	0.38	0.3	0.271	0.22	0.16
	MAPE	2.18	3.54	0.43	1.06	1.15	0.17
	MAE	0.35	0.31	0.24	0.19	0.17	0.13
RNN	RMSE	0.44	0.34	0.29	0.28	0.22	0.19
	MAPE	2.56	2.81	0.4	1.07	1.07	0.19
	MAE	0.33	0.27	0.23	0.2	0.18	0.16
GRU	RMSE	0.46	0.37	0.31	0.28	0.25	0.24
	MAPE	2.08	3.2	0.43	1.38	1.04	0.24
	MAE	0.35	0.3	0.25	0.21	0.2	0.2

## 9. ANALISIS ATAU HASIL EKSPERIMEN PENGUJIAN

Hasil penelitian yang diperoleh, yaitu terdapat pada gambar 6 dan tabel 3 untuk Provinsi Jawa Timur serta gambar 7 dan tabel 4 untuk Provinsi NTT. Pada bagian ini akan dilakukan perbandingan dari ketiga model yang digunakan untuk memprediksi SPEI-6 dan SPEI-12 dari kedua provinsi tersebut. Berdasarkan gambar 6 hasil prediksi *training*, *validation*, dan *testing* nilai SPEI-6 dan SPEI-12 untuk wilayah Provinsi Jawa Timur dari algoritma RNN, LSTM, dan GRU sudah sangat mendekati nilai yang sesungguhnya. Begitu pula dengan hasil prediksi *training*, *validation*, dan *testing* nilai SPEI-6 dan SPEI-12 wilayah Provinsi NTT pada gambar 7 hasil prediksinya sudah sangat mendekati nilai yang sesungguhnya dari ketiga model yang digunakan.

Berdasarkan tabel hasil metrik evaluasi Provinsi Jawa Timur, nilai RMSE (*Root Mean Square Error*) pada testing SPEI-6 LSTM adalah 0.47, sedangkan untuk RNN adalah 0.39, dan GRU adalah 0.45. Begitu pula dengan hasil SPEI-12, masing-masing LSTM, RNN dan GRU memiliki nilai 0.27, 0.29, dan 0,27. Dalam kasus ini, RMSE semakin rendah nilainya akan semakin baik, sehingga model RNN memberikan hasil terbaik dengan nilai RMSE terendah. MAPE (*Mean Absolute Percentage Error*) yang mengukur kesalahan rata-rata dengan acuan semakin rendah nilai MAPE, performa model akan semakin baik. Pada hasil tabel evaluasi metrik Provinsi Jawa Timur nilai MAPE SPEI-6 pada testing LSTM adalah 1.12%, RNN adalah 1%, dan GRU dengan nilai 1.03%. Sedangkan untuk SPEI-12 pada testing nilai MAPE LSTM adalah 1.24%, RNN adalah 1.72%, dan GRU dengan nilai 1.29%. Pada metrik MAPE dapat dilihat bahwa LSTM memberikan hasil terbaik dengan MAPE terendah.

Kemudian, hasil metrik MAE (*Mean Absolute Error*) pada provinsi Jawa Timur, dapat dilihat pada tabel 3 yang menampilkan nilai MAE *training*, validasi, dan *testing* untuk setiap model dengan index SPEI-6 dan SPEI-12. Pada SPEI-6, nilai MAE *testing* pada LSTM memiliki nilai 0.35, pada model RNN sebesar 0.33, dan model GRU sebesar 0.35. Dari nilai hasil testing tersebut, model yang memberikan hasil terbaik adalah model RNN dengan nilai testing terkecil. Semakin mendekati nilai 0, maka semakin akurat model yang digunakan.

Selanjutnya berdasarkan tabel hasil metrik evaluasi Provinsi Nusa Tenggara Timur, nilai RMSE (*Root Mean Square Error*) pada testing SPEI-6 LSTM adalah 0.3, sedangkan untuk RNN adalah 0.29, dan GRU adalah 0.32. Untuk hasil SPEI-12, masing-masing LSTM, RNN dan GRU memiliki nilai 0.16, 0.19, dan 0,24. Dari hasil tersebut model LSTM akan memberikan hasil lebih baik dengan nilai RMSE terendah. Selanjutnya nilai MAPE (*Mean Absolute Percentage Error*) yang mengukur kesalahan rata-rata Provinsi Jawa Timur nilai MAPE SPEI-6 pada testing LSTM adalah 0.43%, RNN adalah 0.40%, dan GRU dengan nilai 0.43%. Sedangkan untuk SPEI-12 pada testing nilai MAPE LSTM adalah 0.17%, RNN adalah 0.19%, dan GRU dengan nilai 0.24%. Sekali lagi pada metrik MAPE dapat dilihat bahwa LSTM memberikan hasil terbaik dengan MAPE terendah

Kemudian, hasil metrik MAE (*Mean Absolute Error*) pada provinsi Jawa Timur, dapat dilihat pada tabel 3 yang menampilkan nilai MAE *training*, validasi, dan *testing* untuk setiap model

dengan index SPEI-6 dan SPEI-12. Pada SPEI-6, nilai MAE *testing* pada LSTM memiliki nilai 0.35, pada model RNN sebesar 0.33, dan model GRU sebesar 0.35. Pada hasil metrik MAE, bila hasilnya semakin mendekati nilai 0, maka semakin akurat model yang digunakan. Dari nilai hasil *testing* SPEI-6 tersebut, model yang memberikan hasil terbaik adalah model RNN dengan nilai *testing* terkecil. Selanjutnya pada SPEI-12, nilai MAE *testing* pada LSTM sebesar 0.13, pada model RNN sebesar 0.16, dan pada model GRU sebesar 0.2. Dengan begitu, model yang memiliki akurasi paling tinggi adalah model LSTM dengan nilai MAE sebesar 0.13.

## 10. KESIMPULAN

Dalam penelitian ini, digunakan data indeks kekeringan *Standardised Percipitation-Evapotranspiration Index* (SPEI) pada wilayah Provinsi Jawa Timur dan NTT. SPEI yang digunakan adalah SPEI-6 dan SPEI-12 dan bentuk datanya berupa *time series*. Kedua SPEI tersebut digunakan untuk prediksi kekeringan dengan menggunakan model RNN, LSTM, dan GRU. Kemudian, ketiga model tersebut dibandingkan performanya untuk mencari model yang terbaik dengan menggunakan metrik evaluasi RMSE, MAE, dan MAPE. Ketiga metrik evaluasi tersebut jika nilainya semakin kecil maka menunjukkan bahwa model yang digunakan semakin baik.

SPEI-12 dari Provinsi Jawa Timur dan NTT memberikan hasil RMSE, MAPE, dan MAE yang lebih kecil dibandingkan dengan SPEI-6 sehingga SPEI-12 lebih baik datanya untuk memprediksi kekeringan. Dalam memprediksi SPEI-6 pada wilayah Jawa Timur diperoleh model terbaik saat proses *testing* yaitu dengan menggunakan RNN yang mendapatkan hasil RMSE 0.39, MAPE 1, dan MAE 0.32. Untuk memprediksi SPEI-6 pada wilayah Provinsi NTT diperoleh model terbaik saat proses *testing* yaitu RNN dengan memperoleh hasil RMSE 0.29, MAPE 0.4, dan MAE 0.23. Hasil *testing* terbaik yang diperoleh untuk memprediksi SPEI-12 pada wilayah Provinsi Jawa Timur adalah dengan model LSTM yang mendapatkan hasil RMSE 0.27, MAPE 1.24, dan MAE 0.22. Selanjutnya pada wilayah Provinsi NTT hasil *testing* yang terbaik untuk memprediksi SPEI-12 diperoleh oleh LSTM yang mendapatkan hasil RMSE 0.16, MAPE 0.17, dan MAE 0.13.

Dapat disimpulkan pada penelitian kali ini untuk memprediksi SPEI-6 pada wilayah Provinsi Jawa Timur dan NTT model yang terbaik adalah RNN. Sedangkan untuk memprediksi SPEI-12 pada wilayah Provinsi Jawa Timur dan NTT model yang terbaik adalah LSTM.

## Daftar Pustaka

- Achmad Fizal. 2023. *Masuk Musim Kemarau 500 Desa di Jatim Terancam Alami Kering Kritis*. <https://surabaya.kompas.com/read/2023/06/13/210219578/masuk-musim-kemarau-500-desa-di-jatim-terancam-alami-kering-kritis>. 30 Juni 2023
- Ali Achmad Noor Hidayat. 2023. *BRIN Sebut El Nino Berpotensi Turunkan Produksi Padi Hingga Satu Juta Ton*. <https://bisnis.tempo.co/read/1739415/brin-sebut-el-nino-berpotensi-turunkan-produksi-padi-hingga-1-juta-ton>. 30 Juni 2023.
- Badan Nasional Penanggulangan Bencana (BNPB). 2018. *487 Juta Jiwa Penduduk Terdampak Kekeringan yang Tersebar di 4.053 Desa*. <https://bnpb.go.id/berita/487-juta-jiwa-penduduk-terdampak-kekeringan-yang-tersebar-di-4053-des>. 30 Juni 2023
- BMKG Stasiun Klimatologi Jawa Timur. 2023. *Rilis Prakiraan Musim Kemarau 2023 Provinsi Jawa Timur*. <https://staklim-jatim.bmkg.go.id/index.php/profil/meteorologi/list-all-categories/536-konferensi-pers/555560022-rilis-prakiraan-musim-kemarau-2023-provinsi-jawa-timur>. 30 Juni 2023.
- Beguéría, S., Vicente-Serrano, S.M., Reig, F. and Latorre, B., 2014. Standardized precipitation evapotranspiration index (SPEI) revisited: parameter fitting, evapotranspiration models, tools, datasets and drought monitoring. *International journal of climatology*. 34(10): 3001-3023.
- Chen, Z., Xu, H., Jiang, P., Yu, S., Lin, G., Bychkov, I., Hmel'nov, A., Ruzhnikov, G., Zhu, N., & Liu, Z. 2021. A transfer Learning-Based LSTM strategy for imputing Large-Scale consecutive missing data and its application in a water quality prediction system. *Journal of Hydrology*. 602:1-16.
- Indarto, I., Wahyuningsih, S., Pudjojono, M., Ahmad, H. dan Yusron, A. 2014. Studi Pendahuluan tentang Penerapan Metode Ambang Bertingkat untuk Analisis Kekeringan Hidrologi pada 15 DAS di Wilayah Jawa Timur. *Jurnal Agroteknologi*. 8(2):112-121.
- Kementerian Pendayagunaan Aparatur Negara dan Reformasi Birokrasi (PANRB). 2023. *BMKG: Tiga Wilayah akan Alami Musim Kemarau Lebih Awal*. <https://www.menpan.go.id/site/berita-terkini/berita-daerah/bmkg-tiga-wilayah-akan-alami-musim-kemarau-lebih-awal>. 30 Juni 2023



- Kukuh Prasetyaningtyas. 2023. *Analisis Dinamika Atmosfer Dasarian II Juni 2023*. <https://www.bmkg.go.id/iklim/dinamika-atmosfir.bmkg>. 30 Juni 2023
- Masri, F., Saepudin, D. and Adytia, D., 2020. Forecasting of Sea Level Time Series using Deep Learning RNN, LSTM, and BiLSTM, Case Study in Jakarta Bay, Indonesia. *e-Proceeding Eng.* 7(2):8544-8551.
- Mishra, A.K. and Singh, V.P., 2010. A review of drought concepts. *Journal of hydrology*, 391(1-2):202-216.
- Patel, M. M., Tanwar, S., Gupta, R. and Kumar, N. 2020. A deep learning-based cryptocurrency price prediction scheme for financial institutions. *Journal of information security and applications*, 55:2214-2126.
- Rhee, J. and Im, J., 2017. Meteorological drought forecasting for ungauged areas based on machine learning: Using long-range climate forecast and remote sensing data. *Agricultural and Forest Meteorology*, 237:105-122.
- Rizkillah, M. F., & Widiyanesti, S. 2022. Prediksi Harga Cryptocurrency Menggunakan Algoritma Long Short Term Memory (LSTM). *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*. 6(1), 25-31.
- Sari, R., Kusriani, K., Hidayat, T., dan Orphanoudakis, T. 2023. Improved LSTM Method for Predicting Cryptocurrency Price Using Short-Term Data. *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*. 17(1):33-44.
- Shang, J., Zhao, B., Hua, H., Wei, J., Qin, G., & Chen, G. 2023. Application of Informer Model Based on SPEI for Drought Forecasting. *Atmosphere*, 14(6):1-20.
- Shinde, O., Gawde, R. and Paradkar, A., 2021. Image Caption Generation Methodologies. *International Research Journal of Engineering and Technology (IRJET)*. 8(4):3961-3966.
- Sulistiyono, W., Zuliandry, M.I.R. and Haryanto, Y.D., 2023. Uji Verifikasi Data Permukaan Dan Indeks Udara Atas Hasil Model Wrf Dengan Data Observasi Stasiun Meteorologi Sultan Hasanuddin. *OPTIKA: Jurnal Pendidikan Fisika*, 7(1):10-22.
- Vicente-Serrano, S.M., Beguería, S. and López-Moreno, J.I., 2010. A multiscalar drought index sensitive to global warming: the standardized precipitation evapotranspiration index. *Journal of climate*. 23(7):1696-1718.

- Wiranda, L. and Sadikin, M., 2019. Penerapan Long Short Term Memory Pada Data Time Series Untuk Memprediksi Penjualan Produk Pt. Metiska Farma. *Jurnal Nasional Pendidikan Teknik Informatika: JANAPATI*. 8(3):184-196.
- Xu, D., Zhang, Q., Ding, Y. and Zhang, D., 2022. Application of a hybrid ARIMA-LSTM model based on the SPEI for drought forecasting. *Environmental Science and Pollution Research*. 29(3):4128-4144.
- Yalçın, S., Eşit, M. and Çoban, Ö., 2023. A new deep learning method for meteorological drought estimation based-on standard precipitation evapotranspiration index. *Engineering Applications of Artificial Intelligence*. 124:1-15.